零售用户消费行为挖掘与营销策略优化

摘要

本研究旨在通过数据挖掘技术挖掘零售用户消费行为特征，为超市营销策略优化提供数据支持。以胖东来超市 2025 年 1 月至 4 月销售数据为基础，综合运用 Apriori 关联规则算法与 K-Means 聚类算法，分别从商品组合与用户分群两个维度展开分析。研究内容主要包括：通过 Apriori 挖掘高提升度商品关联规则，识别出零食与蔬菜类强关联组合；通过 K-Means 将用户划分为四类价值群体，明确其消费特征。研究结论表明，基于商品关联的陈列优化与基于用户分群的精准营销策略能有效提升零售运营效率与客户价值，为零售企业智能化转型提供实践参考[1]。

关键词：数据挖掘；Apriori 算法；K-Means 聚类；用户行为分析；零售营销

1.引言

在数字经济时代，零售业积累了大量交易数据，但价值挖掘仍显不足。如何从中提取有效信息以驱动精细化运营成为关键[7]。超市运营面临两大挑战：一是通过优化商品陈列与组合促销来促进关联购买；二是识别不同消费特征的顾客群体以实现个性化营销。而大数据在零售业市场预测中的应用，不仅为传统零售企业注入了新的活力，还极大地提高了市场预测的准确性。本研究以胖东来的脱敏销售数据为基础，通过构建用户消费行为分析模型，为零售企业在商品管理、促销策略及客户关系等方面提供数据驱动的决策支持。

2. 数据采集与预处理

2.1 数据来源与描述

本研究数据来源于和鲸数据网站胖东来超市 2025 年 1 月至 4 月的部分销售流水记录，共包含 42816 条交易明细。每条记录包含顾客编号、大类名称、销售日期、商品单价、销售数量、是否促销等 17 个字段。数据涵盖了蔬果、日配、熟食、休闲、家居等十余个商品大类，反映了真实的顾客购买行为。

2.2 数据预处理

2.2.1 数据清洗

重复值处理：对完全重复的字段采取删除的处理方式，仅保留唯一记录。

缺失值处理：数据中仅销售数量字段存在两个缺失值，相对于整体样本量的占比极小，不影响数据整体质量，因此直接删除，未采用复杂的插补方法。

异常值处理：

（1） 删除销售金额和销售数量为负值或零值的记录

```
df = df[(df['销售数量'] > 0) & (df['销售金额'] > 0) & (df['商品单价'] > 0)]
```

（2） 删除销售金额与销售数量和商品单价的乘积不匹配的记录

```
df = df[(df['销售数量'] * df['商品单价']).round(2) == df['销售金额'].round(2)]
```

（3） 删除日期不在有效范围内的记录

```
df['销售日期_parsed'] = pd.to_datetime(df['销售日期'], format='%Y%m%d', errors='coerce')
error_dates = df[df['销售日期_parsed'].isna()]['销售日期'].tolist()
print("无效日期：", error_dates)
df = df.dropna(subset=['销售日期_parsed']).copy()
```

（4） 将“是否促销”字段中出现的具体促销数值转换成字符串“是”

```
df.loc[pd.to_numeric(df['是否促销'], errors='coerce').notna(), '是否促销'] = '是'
```

```
if '是否促销' in df.columns:
    df['促销标志'] = df['是否促销'].map({'是': 1, '否': 0})
```

数据类型转换：将“销售日期”与“销售月份”两个字段都转换成日期类型，确保时间维度的一致性。

```
df['销售日期'] = pd.to_datetime(df['销售日期'], format='%Y%m%d')
df['销售月份'] = pd.to_datetime(df['销售月份'], format='%Y%m')
```

2.2.2 数据集成与转换：

为关联分析构建事务型数据，以顾客编号结合销售日期唯一标识一笔交易，为用户聚类构建特征向量（如消费总额、频次等），并进行 Z-score 标准化。

2.3 数据概览

数据清理后所剩有效数据为 34902 条。

（1）每月的总销售量如图 1 所示，销售额在 1 月春节期间达到峰值，2 月有所回落，3 月逐步回升。整体呈现季节性波动特征，符合现实情况。

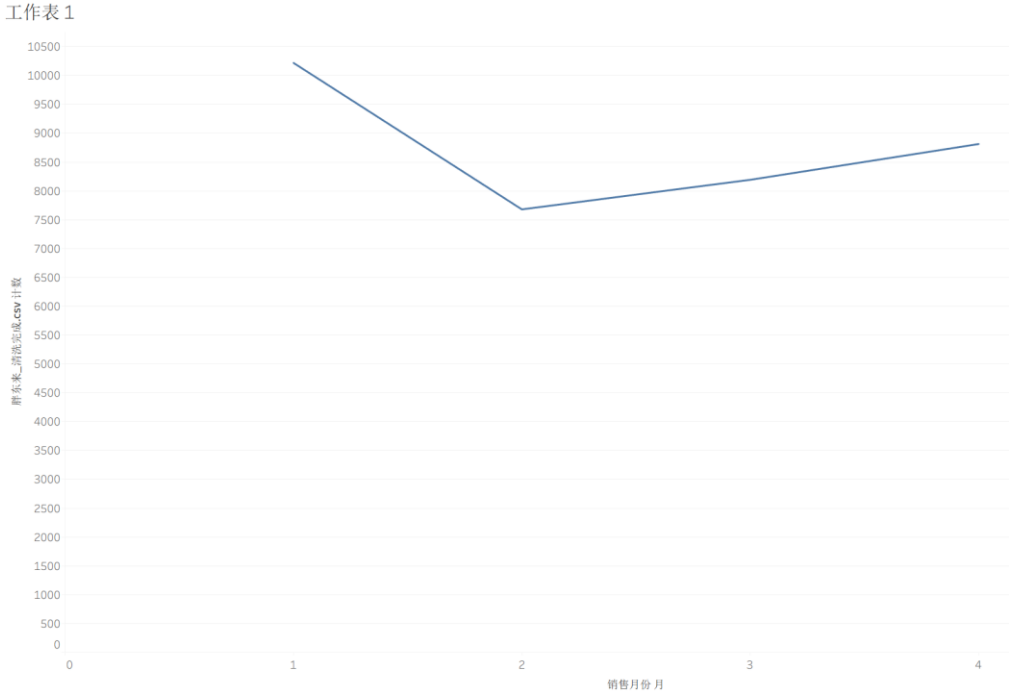


图 1

（2）每个大类的总销售量如图二所示，蔬菜的销售量明显高于其他大类，其他大类之间的差异不明显。

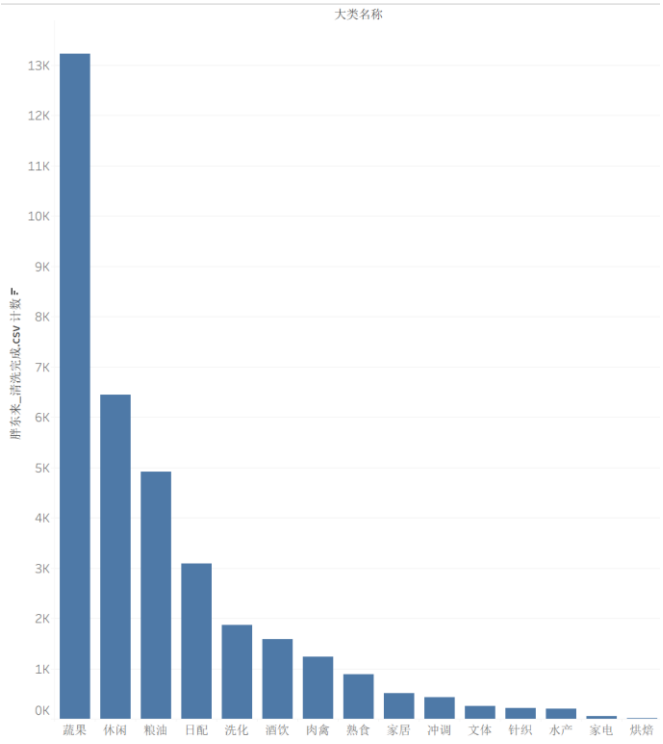


图 2

3. 基于 Apriori 算法的商品关联规则挖掘

3.1 参数设置

本研究使用 mlxtend 库实现 Apriori 算法，参数设置遵循“有效性+业务贴合”原则。最小支持度设为 0.01，仅保留在至少 1%事务中出现的商品组合，避免无实际价值的小众组合。最小置信度设为 0.1，确保规则成立概率不低于 10%。同时要求提升度>1，以排除偶然性关联，仅保留具有正向促进作用的有效规则，为业务决策提供可靠依据[4]。

3.2 分析步骤

分析按“数据适配-核心挖掘-规则筛选-结果整理”流程展开。首先进行事务数据编码，将商品小类列表转换为 759 列的 One-Hot 矩阵。接着挖掘频繁项集，筛选满足最小支持度的商品组合。然后提取关联规则，按置信度进行初步筛选，再通过提升度条件保留正向关联规则。最后将有效规则按置信度降序排列，形成有序结果便于解读应用[8]。

3.3 核心代码

```
from mlxtend.frequent_patterns import apriori, association_rules
from mlxtend.preprocessing import TransactionEncoder
te = TransactionEncoder()
te_ary = te.fit(transactions).transform(transactions)
df_encoded = pd.DataFrame(te_ary, columns=te.columns_)
frequent_itemsets = apriori(df_encoded, min_support=0.01, use_colnames=True)
rules = association_rules(frequent_itemsets, metric="confidence", min_threshold=0.3)
```

3.4 分析结果

共产生了 68 条符合参数设置要求的关联规则，本研究只取前 5 条进行分析。

表 1：前 5 条强商品关联规则

序号	关联规则（前项→后项）	支持度	置信度	提升度
0	其他膨化点心 → 袋装薯片	0.012774	0.526570	11.70110
67	叶菜，菌菇类 → 根茎，花果	0.010966	0.311385	3.160128
61	鲜猪肉，花果 → 根茎	0.019198	0.615828	2.874153
66	叶菜，菌菇类，花果 → 根茎	0.010196	0.595980	2.783105
44	根茎，鲜调味 → 叶菜	0.014532	0.598197	2.774435

根据表 1 结果，可以得出以下主要发现：

（1）规则 0“其他膨化点心 → 袋装薯片”的提升度高达 11.70，显著高于其他规则，表明膨化零食类商品之间存在极强的交叉购买关联。

（2）多条规则涉及多种蔬菜组合，且提升度均大于 2.74，说明消费者倾向于在一次购买中选购多类蔬菜，追求膳食多样性。规则 61 与规则 43 置信度均接近 60%，表明猪肉常与特定蔬菜同时购买，体现了以烹饪为导向的购物行为。

（3）所有规则的支持度均低于 0.022，说明这些强关联模式并非普遍消费行为，而更可能出现在具有特定购物目的如家庭聚餐、制作特定菜肴或特定客群的交易中。

3.5 应用建议

基于上述关联规则，提出以下商品陈列与促销优化建议：

（1）优化生鲜区陈列：将关联性强的商品相邻摆放，如将“鲜猪肉+花果”与“根茎”类商品、“叶菜+菌菇类”与“花果”类商品分别陈列在相近区域，缩短顾客采购路径，激发关联购买。

（2）设计组合优惠套餐：推出“主食材+配菜”形式的优惠套餐，例如“鲜猪肉+花果+根茎”组合或“叶菜+菌菇+花果”组合，提升单次交易金额[6]。

（3）实施智能推荐：在收银系统或线上购物平台中，对购买前项商品的顾客，实时推荐关联的后项商品。

（4）建立库存联动机制：监控核心关联商品的销售情况，当其销量增长时，自动预警并补充其后项关联商品的库存，避免缺货。

（5）挖掘小众需求：在休闲食品区，将“其他膨化点心”与“袋装薯片”相邻陈列，虽然其支持度不高，但极强关联性表明存在稳定的小众需求，值得针对性满足。

4.基于 K-Means 算法的用户聚类分析

4.1 确定参数

肘部法则图的明显拐点与轮廓系数图的最高点都在 k=4 处，因此选择 k=4 作为聚类参数。如图 3 所示。

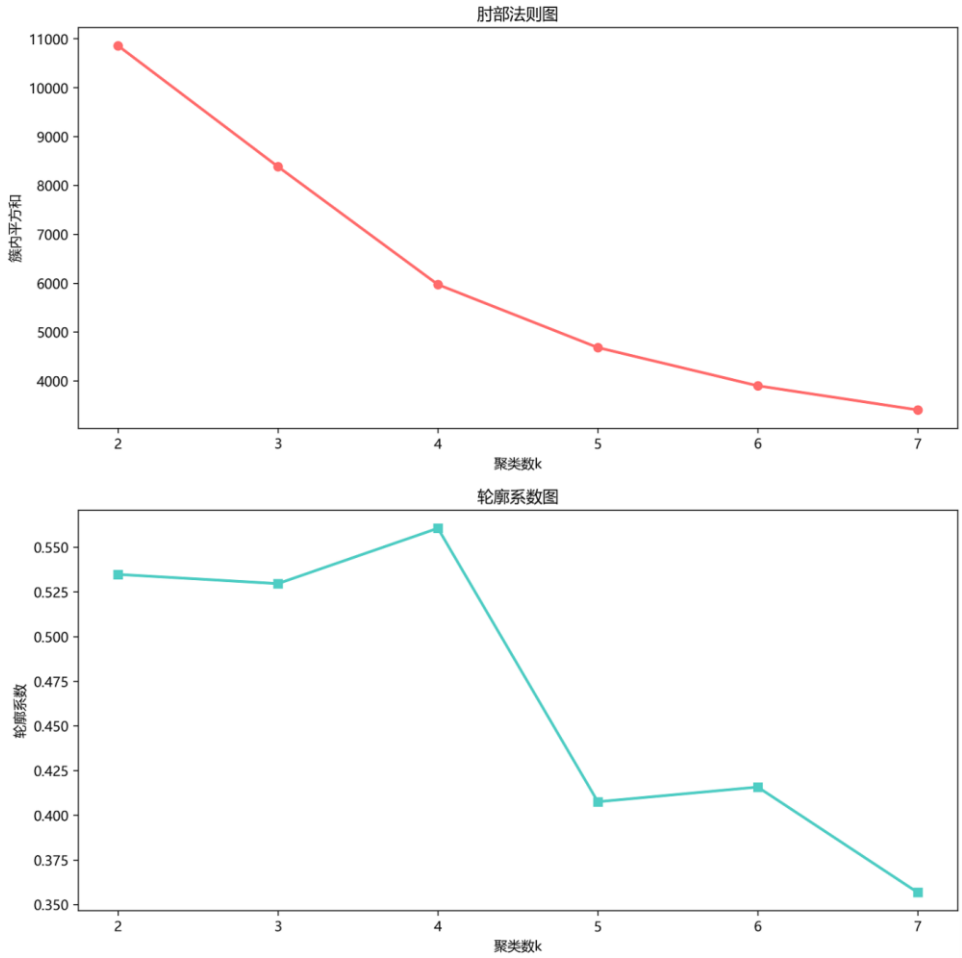


图 3

4.2 分析过程

首先用过肘部法则与轮廓系数确认 k 值，其次将顾客根据不同的消费行为分为四组，最后根据平均总额、单价、频次进行分析。

4.3 核心代码

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
df = pd.read_csv(r'C:\Users\Lenovo\Desktop\胖东来_清洗完成.csv', encoding='utf-8')
customer_features = df.groupby('顾客编号').agg({
    '销售金额': ['sum', 'mean', 'count'],
    '商品单价': 'mean', '大类编码': lambda x: x.nunique(), '促销标志': 'sum'
}).round(2)
customer_features.columns = ['消费总额', '平均单次消费', '消费频次', '平均单价', '购买品类数', '促销次数']
scaler = StandardScaler()
features_scaled = scaler.fit_transform(customer_features[customer_features['消费总额'] <= customer_features['消费总额'].quantile(0.995)])
kmeans = KMeans(n_clusters=4, random_state=42, n_init=10)
customer_features['聚类标签'] = kmeans.fit_predict(features_scaled)
```

4.4 分析结果及应用建议

四类顾客的各项指标如表 2 所示：

表 2：聚合平均指标

	顾客数	占比(%)	平均总额	平均频次	平均单价
大众基础顾客	2046	81.22	70.42	7.82	11.18
高单价低频顾客	352	13.97	416.84	47.78	11.50
高频高价值多样顾客	114	4.53	150.52	2.39	51.89
促销敏感高频顾客	7	0.28	305.61	37.29	8.55

（1）高频高价值多样顾客：消费总额和平均单价均处于最高水平，且购买品类丰富。他们是超市的核心利润贡献者，消费行为成熟且追求品质。

（2）高单价低频顾客：平均单次消费金额最高，但消费频次较低。他们可能偏好高端商品或大规格包装，属于高潜力价值客群。

（3）大众基础顾客：占比最大，构成了超市的消费基本盘。其各项指标均处于中等水平，消费以日常刚需为主，品类相对集中，对价格较为敏感。

（4）促销敏感高频顾客：占比极小，但消费频次极高，且平均单价和总额较低，表明他们非常关注促销活动，可能通过高频次购买低价或促销商品来控制总支出。

4.5 应用建议

针对四类顾客群体的特征，制定差异化营销策略[3]：

（1）高频高价值多样顾客：提供 VIP 专属服务，如快速结账通道、新品优先体验权，设计高价值商品组合优惠套餐，强化客户关系维护，提升其忠诚度[11]。

（2）高单价低频顾客：定期推送高端新品、进口商品或大包装商品信息，提供增值服务，如免费加工、礼品包装，尝试通过会员权益吸引其提高消费频次。

（3）大众基础顾客：保障米面粮油、基础蔬果等刚需品的优质低价供应，推出“小额多品类”搭配套餐，满足一站式购物需求，通过积分兑换等普适性优惠增强粘性。

（4）促销敏感高频顾客：通过 APP 推送、短信等方式定向发送专属折扣券、限时抢购信息，在促销区优化其常购商品的陈列，满足其“薅羊毛”心理，将其转化为稳定客流。

5. 总结与展望

本研究通过 Apriori 与 K-Means 算法，从商品关联与用户分群两个维度构建了零售消费行为分析模型，为胖东来超市提供了陈列优化与精准营销的依据。然而，本研究仍存在以下局限：一是数据时间跨度较短，未涵盖季节性完整周期；二是未融合天气、节假日等外部因素；三是未进行实时预测与动态优化。未来可引入时序预测模型（如 ARIMA）进行销售趋势预测，结合 FP-Growth 算法提升关联挖掘效率，并融合多源数据构建零售智能决策系统，进一步提升模型的实用性与前瞻性。

参考文献

[1]陈佳.大数据在零售业市场预测中的应用[J].商讯,2024,(11):172-174.

[2]杨雁莹.数据挖掘技术的应用[J].电子技术与软件工程,2021,(09):191-192.DOI:10.20109/j.cnki.etse.2021.09.080.

[3]贾静丽.基于数据挖掘技术的预测与决策分析模型[J].贵阳学院学报(自然科学版),2023,18(01):85-90.DOI:10.16856/j.cnki.52-1142/n.2023.01.009.

[4]刘志林,任海帅.基于关联规则的零售企业营销策略优化研究[J].洛阳师范学院学报,2021,40(02):60-66.DOI:10.16594/j.cnki.41-1302/g4.2021.02.015.

[5]谢婷.基于客户价值模型的服装零售 VIP 顾客数据挖掘实证研究[J].商场现代化,2023,(05):13-15.DOI:10.14013/j.cnki.scxdh.2023.05.059.
[6]潘俊豪,张书笠,管翔宇,等.基于数据挖掘的零售企业运营策略推荐研究[J].现代商业,2024,(04):24-27.DOI:10.14097/j.cnki.5392/2024.04.040.
[8]龙迎春.基于 Apriori 算法的商品购物篮分析研究[J].电脑知识与技术,2025,21(20):66-68.DOI:10.14004/j.cnki.ckt.2025.1001.
[9]叶千豪.基于数据强关联的 FP-Growth 算法研究与超市应用[D].哈尔滨商业大学,2024.DOI:10.27787/d.cnki.ghrbs.2024.000119.
[10]王建芳.基于数字技术的智能数据挖掘技术应用研究[J].产业科技创新,2025,7(03):19-22.
[11]刘润嘉,陈浩宇.基于数据挖掘的新零售会员消费数据分析与研究[J].中阿科技论坛(中英文),2025,(02):41-45.
[12]戚文珺.基于数据挖掘和聚类分析的企业零售业务精准营销策略研究[J].现代商业,2024,(17):32-35.DOI:10.14097/j.cnki.5392/2024.17.031.